INFORME TÉCNICO DE INVESTIGACIÓN Y DESARROLLO

Optimización Logística y Búsqueda Adversaria

Resolución Integrada de Rutas con Algoritmos Informados, Metaheurísticas y Teoría de Juegos

Asignatura: Inteligencia Artificial
Módulo: Sistema de Distribución
Fecha: Noviembre 2026

Resumen Ejecutivo: Este informe presenta el diseño, implementación y evaluación experimental de un sistema inteligente de logística y toma de decisiones estratégicas en un entorno heterogéneo de 12×12 celdas. Se evalúa el comportamiento de algoritmos de búsqueda heurística (Greedy Best-First Search y A*), técnicas de optimización combinatoria local (Hill Climbing) y metaheurísticas iterativas (Recocido Simulado y Algoritmos Genéticos). Asimismo, se integra un análisis estratégico mediante Teoría de Juegos (Equilibrio de Nash) y Búsqueda Adversaria por turnos (Minimax con Poda Alfa-Beta) para resolver asignaciones de recursos frente a competidores en entornos de suma cero.

1. DEFINICIÓN DEL ENTORNO Y PROBLEMA LOGÍSTICO

El problema logístico consiste en determinar la ruta óptima para una flota que debe partir desde un origen inicial $S = (0,0)$, visitar una serie de tres puntos de entrega intermedias $D_1 = (2,9)$, $D_2 = (5,3)$, $D_3 = (9,8)$, y finalmente arribar al almacén central $F = (11,11)$. El espacio geográfico se modela mediante una cuadrícula de 12×12 celdas con fricción y costos de elevación/congestión variables **[Russell & Norvig, 2020]**:

- **Terreno Llano (Costo = 1):** Transito fluido de alta velocidad.
- **Zona de Congestión (Costo = 3):** Tráfico moderado o vías secundarias.
- **Zona Difícil / Elevación (Costo = 5):** Alta resistencia al avance y consumo energético elevado.
- **Obstáculos Insalvables (X):** Celdas inaccesibles por bloqueo físico o fallos de infraestructura.

2. BÚSQUEDA HEURÍSTICA E INFRAESTRUCTURA DE RUTAS

Para garantizar el cálculo exacto de distancias mínimas en el mapa heterogéneo, se implementó el algoritmo **A* (A-Star)** empleando como heurística la distancia de Manhattan admisible y consistente:

$$h(n) = |x_n - x_{objetivo}| + |y_n - y_{objetivo}| \quad ; \quad f(n) = g(n) + h(n)$$

Se comparó el algoritmo A* frente a *Greedy Best-First Search*. Mientras que Greedy minimiza únicamente $h(n)$ priorizando la cercanía geométrica (lo que suele derivar en atrapamientos locales rodeados de obstáculos), A* asegura la ruta óptima al ponderar el costo acumulado real $g(n)$.

Con el fin de evitar recálculos redundantes durante las fases combinatorias de ruteo, se construyó previamente una **Matriz de Costos Óptimos Distribuidos** entre todos los pares de nodos clave mediante ejecuciones independientes de A*:

Nodo Origen / Destino	S (0,0)	D1 (2,9)	D2 (5,3)	D3 (9,8)	F (11,11)
S (0,0)	0	15	9	21	26
D1 (2,9)	15	0	12	10	13
D2 (5,3)	9	12	0	14	17
D3 (9,8)	21	10	14	0	5
F (11,11)	26	13	17	5	0

3. BÚSQUEDA LOCAL Y METAHEURÍSTICAS COMBINATORIALES

Con la matriz de costos precomputada, el espacio de soluciones del ruteo se reduce al conjunto de permutaciones de las entregas $\pi \in Perm(\{D_1, D_2, D_3\})$. Se evaluaron tres enfoques de optimización:

1. Hill Climbing (Ascenso de Colina): Explora la vecindad mediante intercambios de pares de entregas (*2-opt swap*). Se evaluaron 10 reinicios aleatorios. Se observó que cuando el algoritmo inicia en secuencias subóptimas distantes, suele estancarse en óptimos locales (costo = 38) debido a la falta de mecanismos para aceptar movimientos cuesta arriba.

2. Recocido Simulado (Simulated Annealing): Supera los óptimos locales aceptando deterioros temporales con una probabilidad gobernada por la regla de Metropolis-Hastings **[Kirkpatrick et al., 1983]**:

$$P(\Delta E, T) = e^{-\Delta E / T} \qquad \text{con esquema geométrico} \qquad T_{k+1} = 0.95 \cdot T_k$$

3. Algoritmo Genético (AG): Evoluciona una población de 10 cromo-permutaciones a lo largo de 20 generaciones. Se empleó selección por torneo (k=3), Cruza de Orden (OX1) para preservar cadenas permutacionales válidas y mutación por intercambio de alelos.

4. EVALUACIÓN EXPERIMENTAL CUANTITATIVA

Se ejecutaron 20 réplicas independientes del Recocido Simulado y del Algoritmo Genético para evaluar su comportamiento estadístico y eficiencia computacional en segundos.

Algoritmo / Metaheurística	Costo Mínimo	Costo Promedio	Mediana Costo	Desv. Estándar	Tiempo Promedio (s)
Recocido Simulado (SA)	36.00	36.00	36.00	0.000	0.00010 s
Algoritmo Genético (AG)	36.00	36.10	36.00	0.447	0.00099 s

Discusión de Resultados: El Recocido Simulado demostró una convergencia determinista hacia la ruta global óptima *(S → D_2 → D_1 → D_3 → F)* con un costo de 36.0 unidades y un tiempo promedio de 0.00010 segundos. Por su parte, el Algoritmo Genético alcanzó la ruta óptima en el 95% de los casos, presentando una ligera dispersión (outliers en costo 38.0) debido al tamaño reducido de la población y el sobrecosto de evaluar operadores genéticos sobre permutaciones cortas, requiriendo 9.9× más tiempo de cómputo.

5. ANÁLISIS ESTRATÉGICO Y DECISIONES ADVERSARIAS

En entornos logísticos reales, la flota interactúa con competidores comerciales por el uso de rutas preferenciales y combustible.

5.1. Juego Simultáneo de Formas Normales (Teoría de Juegos)

Se modeló la interacción entre nuestro Agente (Filas) y el Competidor (Columnas) mediante una matriz de pagos 3×3 de beneficios netos. El análisis de mejores respuestas reveló un **Equilibrio de Nash Puro** en la combinación de estrategias (Ruta Directa R1, Cobertura Regional C1) con un beneficio de (8, 6), donde ningún jugador tiene incentivos unilaterales para desviarse.

5.2. Negociación Adversaria (Minimax con Poda Alfa-Beta)

Se simuló la repartición por turnos de vales de prioridad energética entre el Agente (MAX) y el Rival (MIN). La incorporación de la **Poda Alfa-Beta** logró reducir drásticamente el número de nodos explorados en el árbol de búsqueda sin alterar el valor óptimo devuelto por la raíz:

Algoritmo de Búsqueda	Valor Óptimo Raíz	Nodos Explorados	Nodos Podados	Eficiencia de Poda
Minimax Clásico	14.0	15	0	0.0%
Minimax + Poda Alfa-Beta	14.0	9	6	40.0% de reducción

6. RESILIENCIA, PRUEBAS UNITARIAS Y CONTROL DE ERRORES

Para garantizar la estabilidad operacional, el sistema incorpora validadores rígidos de límites y conectividad. Ante pruebas límite con destinos inaccesibles ubicados en obstáculos X = (2,2), el algoritmo A* retorna `None` de manera controlada y emite alertas de excepción sin interrupciones catastróficas del programa.

7. CONCLUSIONES

La integración de A* con matrices precomputadas constituye la base ideal para resolver problemas de ruteo logístico. Para instancias de tamaño pequeño a mediano, el Recocido Simulado ofrece una relación superior de eficiencia y convergencia respecto a los Algoritmos Genéticos. Por otro lado, la Poda Alfa-Beta demostró ser indispensable en la optimización de árboles de decisión en tiempo real, eliminando el 40% de evaluaciones innecesarias.

REFERENCIAS BIBLIOGRÁFICAS

1. Russell, S., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
2. Kirkpatrick, S., Gelatt, C. D., & Vecchi, M. P. (1983). Optimization by Simulated Annealing. *Science*, 220(4598), 671–680.